

Predicción de flujos observados de entrada y salida por estación en el sistema troncal de TransMilenio mediante aprendizaje automático

Francisco Forero, Juan Ángel Ruiz, Laura Pulecio

17 de marzo de 2026

1. Resumen

Este proyecto propone desarrollar un modelo de aprendizaje automático para predecir flujos observados de entrada y salida por estación en el sistema troncal de TransMilenio, usando intervalos de 15 minutos. El análisis se realizará a nivel agregado estación-tiempo a partir de registros de validaciones diarias y conteos de entradas y salidas por estación. El objetivo es construir una herramienta predictiva para caracterizar patrones temporales de carga y descarga de pasajeros. La metodología se validará inicialmente sobre una troncal o subconjunto de estaciones, con posibilidad de extensión posterior al sistema troncal completo. Como resultados se espera obtener una base de datos consolidada, un modelo predictivo reproducible y una evaluación de desempeño frente a métodos base.

2. Objetivos específicos

1. Construir una base de datos agregada por estación e intervalo de 15 minutos a partir de los registros de validaciones y de los conteos de entradas y salidas del sistema troncal.
2. Caracterizar patrones temporales y espaciales de flujo observado de entrada y salida, identificando diferencias entre estaciones, franjas horarias y días de operación.
3. Desarrollar un modelo de aprendizaje automático para la predicción de corto plazo de flujos observados de entrada y salida por estación.
4. Evaluar el desempeño del modelo frente a métodos base de referencia, como persistencia temporal y promedios históricos por estación y franja horaria.
5. Generar una metodología reproducible para el análisis predictivo de flujos observados por estación a partir de datos abiertos.

3. Breve descripción de la metodología

El proyecto utilizará como fuentes principales los datos abiertos de validaciones diarias y de salidas del sistema troncal de TransMilenio, complementados con la capa oficial de estaciones troncales y con informes institucionales para contextualizar la interpretación de los flujos observados. La unidad de análisis será estación e intervalo de 15 minutos. *Referencia?*

La metodología iniciará con la limpieza, homologación y agregación de datos para construir series temporales consistentes de entradas y salidas observadas por estación. Luego se realizará un análisis exploratorio para identificar patrones diarios, semanales y espaciales del sistema.

A partir de estas series se construirán variables predictoras derivadas del historial reciente de flujo y del calendario operativo, incluyendo rezagos, promedios móviles, hora del día, día de la semana e indicadores de hora pico. Sobre esta base se implementará un modelo principal de aprendizaje automático con XGBoost, aplicado por separado a las series de entradas y de salidas observadas.

La evaluación se realizará mediante particiones temporales de entrenamiento y prueba. El desempeño del modelo se comparará con métodos base de referencia, como persistencia temporal y promedios históricos por estación y franja horaria, usando métricas como MAE y RMSE. La primera implementación se hará sobre una troncal o subconjunto de estaciones para validar el pipeline antes de considerar una extensión al sistema completo.

El desarrollo se apoyará en Python, principalmente con `pandas`, `numpy`, `scikit-learn`, `xgboost` y `matplotlib`.

4. Plan de trabajo

El trabajo se organizará en cuatro etapas.

En la primera etapa se realizará la limpieza, integración y agregación de datos provenientes de las fuentes de validaciones y salidas del sistema troncal. En esta fase se homologarán nombres de estaciones, formatos temporales y estructuras de registro, con el fin de construir una base consistente por estación e intervalo de 15 minutos. Como resultado se espera obtener un conjunto de datos consolidado y una caracterización inicial de los patrones observados de entrada y salida.

En la segunda etapa se desarrollará el componente predictivo. Para ello se construirán variables derivadas del historial reciente de flujo y del calendario operativo, como rezagos temporales, promedios móviles, hora del día, día de la semana e indicadores de hora pico. Con estas variables se implementarán los métodos base de referencia y el modelo principal de aprendizaje automático, inicialmente sobre una troncal piloto o un subconjunto de estaciones, de modo que se pueda validar la estructura general del pipeline.

En la tercera etapa se realizará la evaluación del modelo. Esta fase incluirá la validación temporal de los resultados, la comparación del modelo propuesto frente a los métodos base y el análisis de errores en distintos contextos operativos, como estaciones con diferentes niveles de actividad y franjas horarias de alta y baja demanda. A partir de estos resultados se ajustará el pipeline de predicción y se consolidará la metodología final.

En la cuarta etapa se organizarán y presentarán los resultados del proyecto. Se elaborarán tablas, figuras y visualizaciones que resuman el comportamiento de los flujos observados y el desempeño del modelo predictivo. Finalmente, se redactará el informe del proyecto, incluyendo la discusión metodológica, los hallazgos principales y las posibles extensiones futuras del trabajo.

5. Cronograma tentativo por semanas

Semanas	Actividad principal
1–2	Limpieza de datos, homologación de estaciones y tiempos, y construcción de la base agregada por estación e intervalo de 15 minutos.
3–4	Análisis exploratorio de entradas y salidas e ingeniería de variables temporales.
5–6	Implementación de métodos base y del modelo principal con XGBoost, entrenamiento inicial y evaluación preliminar sobre una troncal piloto o subconjunto de estaciones.
7	Validación temporal, análisis de errores, ajuste del modelo y consolidación de resultados principales.
8	Redacción del informe final, elaboración de figuras y tablas, y preparación de la presentación del proyecto.

6. Referencias

1. TransMilenio S.A. *Portal de datos abiertos de TransMilenio*. Disponible en: <https://datosabiertos-transmilenio.hub.arcgis.com/>
2. TransMilenio S.A. *Validaciones diarias*. Disponible en: https://storage.googleapis.com/validaciones_tmsa/validaciones_diarias.html?
3. TransMilenio S.A. *Salidas*. Disponible en: https://storage.googleapis.com/validaciones_tmsa/Salidas.html?
4. TransMilenio S.A. *Estaciones troncales de TransMilenio*. Disponible en: <https://datosabiertos-transmilenio.hub.arcgis.com/datasets/Transmilenio::estaciones-troncales-de-transmilenio/about>
5. TransMilenio S.A. *Resultados de la estimación de la evasión en el componente troncal, primer semestre de 2024*. Disponible en: <https://www.transmilenio.gov.co/files/f38fb5ba-6c53-4d0f-afa7-b430b221fa16/94cdc6f5-3e9b-4935-9656-4120634f340c/Resultados%20de%20la%20estimaci%C3%B3n%20de%20la%20evasi%C3%B3n%20en%20el%20componente%20troncal%20primer%20semestre%20del%202024.pdf>
6. TransMilenio S.A. *Medición de evasión componente troncal de TRANSMILENIO S.A. 2023-II*. Disponible en: <https://www.transmilenio.gov.co/files/9c018799-b4d1-4161-be47-1428a549cfa8/a9b055bc-11b7-4bdc-ba39-939546df7d46/Medici%C3%B3n%20de%20evasi%C3%B3n%20componente%20troncal%20de%20TRANSMILENIO%20S.A.%202023-II.pdf>
7. TransMilenio S.A. *Informe de gestión y sostenibilidad 2025 de TRANSMILENIO S.A.*. Disponible en: <https://www.transmilenio.gov.co/files/a0f67b20-7bfb-45e1-bf50-8de36667e0c7/a0f6bf58-f43f-42a3-abc8/Informe-de-gestion-y-sostenibilidad-2025-de-TRANSMILENIO.pdf>